

Descente d'échelle du modèle de vagues MFWAM vers le modèle de vagues WW3 autour de la France métropolitaine



Source : Le Télégramme, le 19 novembre 2024

réalisé par

Mathilde Ferreira

Tuteurs

Frank Guibert, Daniel Ruiz

Table des matières

1	Introduction	2
2	Présentation de l'organisme d'accueil	3
2.1	Météo-France : missions et organisation	3
2.2	Implantation territoriale	3
2.3	Le département de Prévision Marine et Océanographique	4
2.4	Le Laboratoire d'Intelligence Artificielle (LabIA)	5
2.5	Environnement technique et infrastructure de calcul	6
3	Contexte scientifique et données	6
3.1	Principes généraux de la prévision des vagues	6
3.2	Les modèles numériques de vagues	7
3.3	État de l'art	10
3.4	Données utilisées	12
4	Méthodologie et techniques mises en œuvre	13
4.1	Formulation du problème de descente d'échelle	13
4.2	Formalisation mathématique du problème	14
4.3	Approches de modélisation	14
4.4	Modèles neuronaux directs	15
4.5	Modèles autorégressifs	17
4.6	Modèles de diffusion conditionnelle	17
4.7	Fonctions de coût et métriques d'évaluation	20
5	Résultats	22
5.1	Protocole d'évaluation	22
5.2	Modèles évalués	22
5.3	Résultats qualitatifs	22
5.4	Métriques quantitatives	25
5.5	Comparaison des coûts de calcul	27
5.6	Analyse critique	28
6	Conclusion du projet	29
6.1	Limites de l'étude	30
6.2	Perspectives d'amélioration méthodologiques	30
6.3	Perspectives spécifiques aux modèles de diffusion	31
6.4	Vers une mise en production opérationnelle	32
7	Conclusion personnelle	32
	Glossaire	34

Bibliographie	36
----------------------	-----------

1 Introduction

La prévision de l'état de la mer constitue un enjeu majeur pour les activités maritimes et côtières. Elle intervient dans de nombreux domaines tels que la sécurité de la navigation, la gestion des risques naturels, les opérations de secours en mer, ou encore l'aménagement et la protection du littoral. En France métropolitaine, ces prévisions sont produites de manière opérationnelle par Météo-France et s'appuient principalement sur des modèles numériques de prévision des vagues, couplés à des modèles atmosphériques fournissant les champs de vent nécessaires à leur forçage.

Les modèles physiques actuellement utilisés, tels que WaveWatch III (WW3) ou MFWAM, reposent sur une description détaillée des processus physiques gouvernant la génération et la propagation des vagues. Bien que leur fiabilité soit éprouvée, ces modèles présentent un coût de calcul élevé, en particulier lorsqu'ils sont déclinés à haute résolution spatiale ou intégrés dans des systèmes de prévision d'ensemble. Or, le développement de la prévision probabiliste constitue aujourd'hui un axe stratégique fort, notamment pour l'anticipation et la gestion des événements extrêmes tels que les tempêtes ou les phénomènes de vagues-submersion.

Dans ce contexte, les méthodes d'intelligence artificielle, et en particulier l'apprentissage profond, offrent de nouvelles perspectives pour la modélisation des systèmes géophysiques. En exploitant de grandes quantités de données issues des modèles numériques et des observations, ces approches permettent d'approximer des relations complexes à un coût de calcul bien inférieur à celui des modèles physiques traditionnels. Elles apparaissent ainsi comme des candidates pertinentes pour compléter certaines chaînes de prévision numérique, notamment dans une optique de rapidité de calcul et de sobriété énergétique.

Ce projet de fin d'études s'inscrit dans cette dynamique et a été réalisé au sein de Météo-France, en collaboration avec le Laboratoire d'Intelligence Artificielle (DSM/LabIA) et le département de Prévision Marine et Océanographique (DIROP/MAR/RD). Il vise à étudier la faisabilité d'un modèle d'apprentissage profond capable de réaliser une descente d'échelle des prévisions de vagues autour de la France métropolitaine, à partir de forçages atmosphériques et de conditions aux limites issues de modèles de plus grande échelle. L'objectif n'est pas, dans un premier temps, de remplacer les modèles déterministes physiques opérationnels, mais de proposer une alternative plus rapide pouvant fournir des prévisions intermédiaires ou servir de base à un futur système de prévision d'ensemble à moindre coût.

Plus précisément, le travail consiste à développer et évaluer plusieurs approches de modélisation statistique, incluant des modèles neuronaux directs, des formulations autorégressives, des méthodes basées sur l'apprentissage du résidu, ainsi que des modèles de diffusion conditionnelle. Ces différentes stratégies sont comparées en termes de qualité de prévision, de cohérence spatiale et de capacité à reproduire les structures fines des champs de vagues. L'évaluation repose sur des métriques quantitatives issues de la littérature, mais également sur une analyse qualitative des champs simulés, en lien avec les attentes des prévisionnistes.

Au-delà des aspects scientifiques et techniques, ce projet s'inscrit également dans une réflexion plus large sur les enjeux de responsabilité sociétale et de développement durable. La réduction du coût de calcul des chaînes de prévision numérique représente en effet un levier important pour limiter l'empreinte énergétique des infrastructures de calcul intensif, tout en améliorant la réactivité des services de prévision à destination des acteurs de la

sécurité civile et maritime.

Ce rapport est structuré de la manière suivante. La première partie présente Météo-France, le service d'accueil et l'environnement technique dans lequel s'est déroulé le projet. La deuxième partie est consacrée au contexte scientifique et aux données utilisées, en particulier aux modèles de vagues et aux forçages atmosphériques. La troisième partie détaille la méthodologie suivie et les techniques d'apprentissage mises en œuvre. Les résultats obtenus et leur analyse critique sont présentés dans une quatrième partie. Enfin, le rapport se conclut par une synthèse des apports du projet, une discussion sur les perspectives opérationnelles, ainsi qu'un retour personnel sur les compétences acquises au cours de ce stage.

2 Présentation de l'organisme d'accueil

2.1 Météo-France : missions et organisation

Météo-France est l'établissement public national chargé de la météorologie et du climat en France. Placé sous la tutelle du ministère de la Transition écologique, il a pour missions principales la surveillance de l'atmosphère et de l'océan, la production de prévisions météorologiques et climatiques, ainsi que la diffusion de l'information météorologique auprès des pouvoirs publics, des acteurs économiques et du grand public.

L'établissement joue un rôle essentiel dans la prévention et la gestion des risques naturels, notamment en lien avec les phénomènes météorologiques dangereux tels que les tempêtes, les fortes précipitations, les vagues-submersion ou les épisodes de canicule. À ce titre, Météo-France contribue directement à la sécurité des personnes et des biens à travers des dispositifs opérationnels tels que la vigilance météorologique.

Météo-France s'appuie également sur une activité de recherche et développement de haut niveau, visant à améliorer en continu la compréhension des processus atmosphériques et océaniques, ainsi que la qualité et la fiabilité des prévisions. Ces activités s'inscrivent dans un cadre international, en collaboration avec de nombreux organismes scientifiques et institutions météorologiques.

L'établissement compte environ 2 500 agents et dispose d'un budget annuel de l'ordre de 350 millions d'euros. Son organisation repose sur une articulation entre services centraux, directions interrégionales et un réseau dense d'observation comprenant stations automatiques, radars météorologiques, bouées océaniques et satellites.

2.2 Implantation territoriale

La direction générale de Météo-France est située à Saint-Mandé, en région parisienne. La majorité des services centraux, incluant la prévision, la recherche, les systèmes d'observation et les activités informatiques, est toutefois implantée à Toulouse, sur le site de la Météopole. Ce centre regroupe une grande partie des compétences scientifiques et techniques de l'établissement et constitue un pôle majeur de la météorologie européenne.

En complément, Météo-France dispose d'un réseau territorial structuré autour de sept directions interrégionales en métropole, ainsi que de services météorologiques présents dans les départements et collectivités d'outre-mer. Cette organisation permet d'assurer une couverture fine du territoire national et de répondre aux besoins spécifiques des différents bassins géographiques, notamment en matière de prévision marine et côtière.

La Figure 1 illustre l'implantation de Météo-France sur l'ensemble du territoire métropolitain.




FIGURE 1 – L'implantation de Météo-France dans l'Hexagone. Source : Météo-France

2.3 Le département de Prévision Marine et Océanographique

Le département de Prévision Marine et Océanographique (DirOP/MAR) est en charge de l'expertise, du pilotage et de la production des prévisions et services liés aux domaines marins et océaniques. Il intervient aussi bien pour les missions institutionnelles de service public que pour les prestations à destination de clients commerciaux.

Dans le cadre des missions institutionnelles, le département assure notamment la production des prévisions nécessaires à la sécurité maritime et à la gestion des risques côtiers. Il contribue ainsi aux dispositifs de vigilance, en particulier à la vigilance Vagues-Submersion, destinée à anticiper les phénomènes dangereux affectant le littoral, un exemple de carte de vigilance est représenté en Figure 2.




FIGURE 2 – Carte de Vigilance Vagues Submersion simulée pour le samedi 27 février 2010 à 16 h lors de la tempête Xynthia - Source : Météo-France

Ce département joue un rôle central dans l'orientation et la validation des évolutions des chaînes de prévision numérique marine, en lien étroit avec les équipes de recherche et les services de développement informatique.

2.4 Le Laboratoire d'Intelligence Artificielle (LabIA)

Le projet de fin d'études présenté dans ce rapport a été réalisé au sein du Laboratoire d'Intelligence Artificielle (LabIA), rattaché à la Direction des Services Météorologiques (DSM). Créé en 2019 après avoir bénéficié d'un Fond de Transformation de l'Action Publique, le LabIA a pour vocation de centraliser et d'accompagner les projets d'intelligence artificielle à vocation opérationnelle au sein de Météo-France.

L'équipe du LabIA est composée de profils complémentaires, incluant des data scientists, des ingénieurs logiciels, des développeurs spécialisés en Python et un spécialiste en météorologie. Elle intervient sur l'ensemble du cycle de vie des projets d'IA, depuis l'étude de faisabilité et le prototypage jusqu'à la mise en production, en collaboration étroite avec les directions métiers.

Le fonctionnement du LabIA repose sur des méthodes de travail inspirées des pratiques agiles, avec une organisation par sprints, une gestion des tâches sous forme de tickets, des revues de code régulières et l'utilisation d'outils collaboratifs tels que GitHub et Gitlab. Cette organisation favorise la qualité du code, la traçabilité des développements et la montée en compétence collective.

Dans le cadre de ce projet, le LabIA a assuré l'encadrement technique en intelligence artificielle, tandis que le département de Prévision Marine et Océanographique a apporté l'expertise métier nécessaire à la compréhension des enjeux opérationnels et à l'évaluation

des résultats.

2.5 Environnement technique et infrastructure de calcul

Les expérimentations réalisées dans le cadre de ce projet ont nécessité l'utilisation de ressources de calcul intensif adaptées à l'entraînement de modèles d'apprentissage profond. Le LabIA dispose à cet effet d'une infrastructure mutualisée composée de cinq nœuds de calcul équipés de 4 GPUs (Nvidia Tesla V100), ainsi que d'un nœud CPU dédié aux phases de prétraitement des données.

3 Contexte scientifique et données

3.1 Principes généraux de la prévision des vagues

Les vagues de surface résultent principalement de l'interaction entre le vent et la surface de l'océan. Leur évolution dépend de nombreux processus physiques tels que la génération par le vent, la propagation, la dissipation par déferlement, ainsi que les interactions non linéaires entre les différentes composantes spectrales. À proximité des côtes, ces phénomènes sont en outre influencés par la bathymétrie, la topographie côtière et les effets de réfraction ou de diffraction.

La prévision numérique des vagues repose sur des modèles spectraux qui décrivent l'état de la mer à travers un spectre directionnel d'énergie. Ces modèles résolvent une équation de bilan d'énergie prenant en compte les principaux termes sources et puits. Les sorties des modèles permettent de dériver un ensemble de paramètres intégrés, tels que la hauteur significative de la mer, les périodes caractéristiques ou les directions moyennes de propagation.




FIGURE 3 – Description des paramètres de vagues. [7]

Dans un contexte opérationnel, ces prévisions sont essentielles pour la sécurité maritime, la gestion des risques côtiers et l'aide à la décision des autorités. Elles doivent être fiables, cohérentes spatialement et disponibles dans des délais compatibles avec les contraintes opérationnelles.

3.2 Les modèles numériques de vagues

MFWAM

MFWAM un modèle de prévision des états de mer (mer du vent et houles) de grande échelle. C'est un modèle global ou régional, utilisé en particulier pour prévoir les vagues sur plusieurs jours (presque 5 jours). Il est utilisé par les prévisionnistes principalement en mer profonde et avant que les runs de WW3 ne soient disponibles, car il est plus long à calculer.

En fonction des configurations, MFWAM est forcé par des vents à 10 m issus des modèles de prévision numérique du temps, notamment ARPEGE et AROME pour les configurations européennes et locales.

Une version stabilisée de MFWAM est opérationnelle depuis mars 2011 dans sa configuration globale, forcée par les vents issus d'IFS/CEP et assimilant les observations spatiales disponibles. En effet, les sorties de MFWAM sont régulièrement validées par rapport à des observations indépendantes (bouées houlographiques, mesures in situ) afin de mesurer la qualité des prévisions et d'orienter les améliorations du modèle.

Le cycle de production des prévisions est renouvelé quatre fois par jour (de 00h, 06h, 12h et 18h), couvrant ainsi un horizon temporel s'étendant jusqu'à 102 heures. Les échéances sont faites avec un pas de temps de 1h jusqu'à 48h puis de 3h. La résolution spatiale du modèle est de 0.1° (soit environ 10km).

WaveWatch III

WaveWatch III (WW3) est un modèle numérique spectral de vagues développé par la National Oceanic and Atmospheric Administration (NOAA) [14]. Il est largement utilisé à l'échelle internationale pour la modélisation et la prévision des états de mer, et constitue la référence opérationnelle de Météo-France pour les applications côtières. Il est imbriqué dans des modèles MFWAM de plus grande échelle.

Dans ce travail, WW3 est utilisé comme modèle de référence à haute résolution pour l'apprentissage et l'évaluation des méthodes de downscaling. Les données proviennent de la configuration côtière opérationnelle de Météo-France, développée en partenariat avec le Service hydrographique et océanographique de la marine (SHOM).

Cette configuration repose sur un maillage non structuré permettant d'adapter la résolution spatiale en fonction de la complexité du littoral, montré sur la Figure 4.




FIGURE 4 – Maillage du modèle WW3 sur l'Atlantique. [8]

La résolution atteint environ 200 m à proximité des côtes et diminue progressivement vers le large, jusqu'à environ 300 km des côtes métropolitaines. Sur la Figure 5, les 5 domaines du modèle sont représentés : la Bretagne, la Manche, la Gascogne, le golfe du Lion et la Corse.




FIGURE 5 – Domaines du modèle WW3 à la résolution 200m autour de la France métropolitaine.

Le modèle est forcé par :

- des champs de vent à 10 m issus de modèle atmosphérique global ARPEGE ou régional AROME.
- des courants océaniques barotropes et hauteur d'eau issus du modèle Hycom2D forcé par ARPEGE.
- des conditions aux limites fournies par le modèle de vagues global MFWAM.

L'intérêt principal de cette configuration, dans le cadre du downscaling, est sa capacité à représenter des structures fines liées à la bathymétrie et à la géométrie côtière, tout en conservant une cohérence à plus grande échelle grâce aux conditions aux limites issues d'un modèle global.

La prévision est produite quatre fois par jour (00 h, 06 h, 12 h et 18 h) et une analyse horaire est disponible. Dans ce projet, les analyses WW3 sont utilisées comme vérité terrain pour entraîner et évaluer les modèles d'apprentissage profond.

Modèles	MFWAM	WW3
Cas d'utilisation	Large	Côtier
Résolution	0.1°	0.002°
Forçage	horaire : ARPEGE	toutes les 3h : ARPEGE Niveau eau et courants de surface Hycom
Pas de prévision	1h jusqu'à 48h puis 3h jusqu'à 102h	1h jusqu'à 48h puis 3h jusqu'à 72h
Réseaux	00h, 06h, 12h, 18h	00h, 06h, 12h, 18h
Disponibilité après le début du run	~ 4h30	~ 8h

TABLE 1 – Tableau de comparaison entre les modèle de vagues MFWAM et WW3.

Le modèle atmosphérique ARPEGE

Les modèles de vagues nécessitent des champs de vent de surface pour être forcés. Dans ce projet, ces champs sont fournis par le modèle atmosphérique ARPEGE (Action de Recherche Petite Échelle Grande Échelle), développé et exploité par Météo-France.

ARPEGE est un modèle de prévision numérique du temps global à maille variable, offrant une résolution plus fine sur l'Europe et la France métropolitaine. Il fournit des prévisions des composantes zonale et méridienne du vent à 10 mètres.




FIGURE 6 – Exemple de données utilisés dans le projet. Paramètres de vent ARPEGE (U (zonale) et V (méridienne)) à gauche, les sorties du modèle MFWAM au centre et les sorties du modèle WW3 à droite.

3.3 État de l’art

Dans cette section, nous présentons un état de l’art ciblé sur les approches de downscaling spatial appliquées aux phénomènes géophysiques, en mettant particulièrement l’accent sur les méthodes d’apprentissage profond. Ce survol permet de situer le travail réalisé dans ce rapport par rapport aux développements récents dans la littérature scientifique.

Downscaling géophysique par apprentissage profond

Le downscaling, qui consiste à générer des champs haute résolution à partir de données résolues grossièrement, est une problématique centrale en sciences de la Terre, tant pour la prévision météorologique que pour les projections climatiques à petite échelle. Historiquement, les approches statistiques et les modèles dynamiques régionaux ont été employés pour affiner les champs numériques. Toutefois, ces techniques exigent des ressources de calcul importantes ou ne parviennent pas à restituer fidèlement les détails locaux. L’ap-

prentissage profond permet de traiter ces limitations en apprenant une transformation non linéaire entre champs de basse et de haute résolution, tout en réduisant le coût de calcul relatif par rapport aux méthodes physiques traditionnelles.

Des exemples récents en climatologie montrent l'utilisation de réseaux d'apprentissage profond pour le downscaling de champs atmosphériques ou hydrologiques à haute résolution. Par exemple, des modèles génératifs ont été appliqués pour augmenter la résolution spatiale et temporelle des précipitations globales à partir de réanalyses ERA5, passant d'une résolution de 24km / 1h à des résolutions proches de 2km / 10min [2]. Ces travaux démontrent que les architectures conditionnelles peuvent apprendre à synthétiser des structures fines et réalistes à partir d'entrées grossières.

Réseaux convolutionnels et super-résolution

Les premières tentatives de super-résolution spatiale avec des réseaux de neurones profonds s'inspirent des travaux en vision par ordinateur, où des architectures CNN ont été utilisées pour améliorer la résolution d'images numériques. Ces architectures permettent d'intégrer efficacement des informations spatiales et multi-échelle. Dans le domaine environnemental, des CNN ont également été utilisés pour le downscaling de variables atmosphériques ou océaniques, montrant que l'utilisation de couches convolutionnelles profondes améliore la reconstruction avec des détails spatiaux fins (par exemple, pour les prévisions de vent à haute résolution) [5].

Cependant, les réseaux convolutionnels classiques peuvent manquer de capacité pour modéliser des dépendances à très grande échelle ou pour représenter correctement les distributions des extrêmes. En particulier, l'utilisation de fonctions de perte ponctuelles traditionnelles comme l'erreur quadratique moyenne (MSE) tend à produire des champs visuellement lisses qui atténuent les détails localisés. Cette limitation est largement reconnue dans la littérature sur la super-résolution géophysique.

GANs pour la super-résolution et le downscaling

Les réseaux antagonistes génératifs (GAN) constituent une classe d'approches étudiées pour la super-résolution conditionnelle, qui est conceptuellement proche du downscaling. Les GAN conditionnels permettent de produire des détails réalistes et de capturer des statistiques plus complexes des données haute résolution à partir d'entrées basse résolution, ce qui est un avantage par rapport aux CNN standards. Des modèles comme les cGAN ont été proposés pour le downscaling des champs de précipitations, restituant des motifs spatiaux réalistes et des distributions de taux de pluie y compris pour les événements extrêmes [2].

Un avantage des GAN est leur capacité à générer plusieurs solutions plausibles pour une même entrée basse résolution, ce qui permet d'explorer la variabilité possible des champs générés au lieu de proposer une unique reconstruction déterministe. Cependant, les GAN sont parfois instables à entraîner et sensibles aux hyperparamètres, ce qui peut compliquer leur usage dans des applications opérationnelles de longue durée.

Approches basées sur les modèles de diffusion

Plus récemment, les modèles de diffusion ont émergé comme une alternative robuste aux GAN pour les tâches de génération conditionnelle. Ces modèles apprennent à inverser

un processus de diffusion stochastique, générant des sorties qui respectent la distribution conditionnelle des données haute résolution, tout en étant moins vulnérables aux instabilités d'entraînement associées aux GAN. Dans le contexte du downscaling géophysique, des travaux récents ont montré que des modèles de diffusion latente peuvent être utilisés pour émuler des simulations de modèles régionaux à haute résolution à partir de réanalyses grossières, avec une capacité à préserver des caractéristiques fines et des structures locales [15]. Ce type d'approche de Latent Diffusion Model (LDM) appliqué au downscaling météorologique montre des améliorations significatives par rapport aux méthodes de référence et offre une alternative potentiellement plus stable et efficace que les GAN.

Les modèles de diffusion ont également été explorés dans d'autres domaines physiques pour reconstruire des champs complexes, tels que la température de surface de la mer ou la modélisation multi-variables pour les projections climatiques, illustrant la capacité de ces architectures à apprendre des structures spatiales complexes [16].

L'état de l'art montre que :

- les CNN classiques permettent de réaliser un downscaling spatial efficace, mais leur sortie est souvent lissée si l'on utilise des fonctions de perte classiques.
- les GAN introduisent une capacité à générer des détails plus réalistes, tout en étant parfois instables à entraîner.
- les modèles de diffusion constituent une voie récente prometteuse pour la génération de champs détaillés et cohérents statistiquement.

3.4 Données utilisées

Dans ce projet, les jeux de données suivants ont été exploités :

- **Analyses WW3** : sorties analysées du modèle WW3 forcé par ARPEGE, disponibles toutes les heures à une résolution d'environ 200 m (Figure 5).
- **Prévisions MFWAM** : prévisions forcées par ARPEGE, à une résolution d'environ 10 km, disponibles pour les échéances 1 h à 102 h, émises aux réseaux 00, 06, 12 et 18 UTC.
- **Paramètres de vagues** : pour chaque champ, nous conservons sept paramètres : la hauteur significative de la mer totale, puis pour la mer du vent et la houle dominante : hauteur, période et direction.
- **Bathymétrie** : sortie bathymétrique fournie par WW3.
- **Champs de vent** : composantes zonale (U) et méridienne (V) à 10 m issues d'ARPEGE, utilisées comme forçage atmosphérique.
- **Domaines d'étude** : les jeux de données ont été extraits pour la zone Bretagne dans ce rapport.
- **Période d'étude** : les données ont été extraites sur une période d'un an en 2023 pour entraîner nos modèles.

Les données atmosphériques et océanographiques sont fournies au format GRIB. Le GRIB est un format utilisé principalement en météorologie, par tous les services météo pour communiquer des prévisions météo.

Paramètres de vagues utilisés

- **SWH** : hauteur significative de la mer totale (mer du vent + houle), en mètres.
- **SHWW** : hauteur significative de la mer du vent, en mètres.
- **SHPS** : hauteur significative de la houle primaire, en mètres.
- **MPWW** : période moyenne de la mer du vent, en secondes.
- **MPPS** : période moyenne de la houle primaire, en secondes.
- **MDWW** : direction moyenne de la mer du vent, en degrés vrais.
- **MDPS** : direction principale de la houle primaire, en degrés vrais.

Avant l'apprentissage, les données ont fait l'objet d'un prétraitement comprenant :

- la mise en cohérence des grilles spatiales, interpolation vers la grille de résolution 0.002° de WW3.
- la normalisation/standardisation des variables afin de stabiliser l'entraînement (échelles physiques différentes entre vent, hauteurs, périodes, etc.).
- la gestion des valeurs manquantes par masquage.
- la transformation angulaire des directions en composantes trigonométriques ($\sin$, $\cos$) pour garantir la continuité entre 0° et 360° .
- l'utilisation du logarithme de la bathymétrie afin de préserver la dynamique des faibles profondeurs sans écraser l'échelle des grandes valeurs.

4 Méthodologie et techniques mises en œuvre

4.1 Formulation du problème de descente d'échelle

L'objectif du projet est de réaliser une descente d'échelle (*downscaling*) des prévisions de vagues autour de la France métropolitaine à l'aide de modèles d'apprentissage profond. La descente d'échelle consiste à estimer des champs de vagues à haute résolution spatiale à partir d'informations disponibles à plus basse résolution, tout en conservant la cohérence physique et spatiale des phénomènes simulés.

Dans ce cadre, le problème est formulé comme une tâche de régression supervisée. Les entrées du modèle sont constituées de champs atmosphériques et océaniques issus de modèles numériques de plus grande échelle, tandis que les sorties correspondent aux champs de vagues produits par un modèle de référence à plus fine résolution. L'apprentissage repose sur l'exploitation d'un large ensemble de paires entrée-sortie issues de simulations historiques.

Contrairement aux modèles physiques, qui résolvent explicitement les équations gouvernant les processus de génération et de propagation des vagues, les modèles de Deep Learning visent à apprendre une approximation directe de la relation entre les variables d'entrée et les variables de sortie. Cette approche permet de réduire considérablement le coût de calcul, au prix d'une dépendance accrue à la qualité et à la représentativité des données d'apprentissage.

Un entraînement distinct est réalisé pour chaque grille géographique. Ce choix permet de tenir compte des spécificités régionales, notamment en termes de géométrie côtière et de bathymétrie.

Dans ce rapport, nous nous concentrons uniquement sur la Bretagne.

L’objectif opérationnel à long terme de ce travail est de réaliser un downscaling des champs de vagues issus du modèle MFWAM à une résolution de 10 km vers la résolution côtière de WW3, de l’ordre de 200 m.

Un tel changement d’échelle correspond à un facteur d’upscaling d’environ $\times 50$, ce qui constitue un défi majeur. En effet, dans la littérature, les approches de super-résolution et de downscaling dépassent rarement des facteurs de l’ordre de $\times 10$.

Afin de maîtriser progressivement la complexité du problème et d’évaluer la capacité des modèles à apprendre les structures multi-échelles, ce rapport se concentre dans un premier temps sur un facteur de downscaling plus modéré, de $\times 2$, correspondant à un passage de 10 km à 5 km de résolution spatiale.

Cette approche incrémentale permet d’analyser finement les performances des modèles avant d’envisager des facteurs de résolution plus ambitieux.

4.2 Formalisation mathématique du problème

Soit $H \in \mathbb{N}$ la hauteur de l’image, $W \in \mathbb{N}$ la largeur de l’image, $C_x \in \mathbb{N}$ le nombre de canaux de conditionnement (13 dans notre cas : 9 paramètres de vagues à basse résolution, U et V de ARPEGE, la bathymétrie et le masque terre/mer) et $C_y \in \mathbb{N}$ le nombre de canaux haute résolution (9 dans notre cas).

On note :

- $\mathbf{X}_t \in \mathbb{R}^{H \times W \times C_x}$ les champs d’entrée à l’échance t (champs de vent, champs de vagues à basse résolution),
- $\mathbf{Y}_t \in \mathbb{R}^{H \times W \times C_y}$ les champs de vagues de référence à haute résolution,
- f_θ un réseau de neurones paramétré par θ .

Le problème de descente d’échelle est formulé comme l’approximation de la relation suivante :

$$\mathbf{Y}_t = f_\theta(\mathbf{X}_t), \quad (1)$$

Dans le cas d’un modèle autorégressif, la dépendance temporelle est explicitement introduite :

$$\mathbf{Y}_{t+1} = f_\theta(\mathbf{X}_{t+1}, \mathbf{Y}_t). \quad (2)$$

L’apprentissage du modèle consiste à estimer les paramètres θ en minimisant une fonction de coût $\mathcal{L}$ sur un ensemble d’apprentissage $\mathcal{D}$:

$$\theta^* = \arg \min_{\theta} \mathbb{E}_{(\mathbf{X}, \mathbf{Y}) \sim \mathcal{D}} [\mathcal{L}(f_\theta(\mathbf{X}), \mathbf{Y})]. \quad (3)$$

Cette formulation mathématique permet d’unifier les différentes approches explorées dans ce projet, qu’elles soient déterministes ou probabilistes, et constitue le cadre commun à l’ensemble des modèles étudiés.

4.3 Approches de modélisation

Plusieurs stratégies de modélisation ont été explorées dans le cadre de ce projet afin d’évaluer leur capacité à reproduire fidèlement les champs de vagues à haute résolution. Ces approches se distinguent principalement par la manière dont la relation entre les entrées et les sorties est apprise, ainsi que par leur capacité à modéliser la dynamique temporelle et la variabilité spatiale des champs.

Trois grandes familles de modèles ont été considérées :

- des modèles neuronaux directs, apprenant une relation instantanée entre les entrées et les sorties.
- des modèles intégrant une dynamique temporelle explicite, de type autorégressif.
- des modèles probabilistes basés sur des processus de diffusion conditionnelle.

Ces différentes approches sont détaillées dans les sections suivantes.




FIGURE 7 – Schéma conceptuel de la chaîne de descente d'échelle basée sur l'apprentissage profond.

Comme illustré Figure 7, les champs de vent atmosphérique et les paramètres de vagues issues des modèles de grande échelle sont prétraités puis fournis en entrée à un réseau de neurones chargé de produire des champs de vagues à haute résolution.

4.4 Modèles neuronaux directs

Les modèles neuronaux directs visent à prédire les champs de vagues à un instant donné à partir des champs d'entrée disponibles sur la même échéance temporelle. Ils constituent une première approche simple et efficace pour évaluer la capacité d'un réseau de neurones à capturer les relations spatiales entre les forçages atmosphériques et les états de mer basse résolution.

Architecture U-Net

Les architectures de type U-Net sont largement utilisées pour les tâches de prédiction de champs géophysiques en raison de leur capacité à capturer à la fois les structures globales et les détails fins. Elles reposent sur une structure encodeur-décodeur, dans laquelle les informations sont progressivement compressées puis reconstruites à l'aide de connexions de saut (Figure 8).

Dans ce projet, le U-Net est utilisé pour traiter des champs bidimensionnels représentant les variables d'entrée et de sortie. Les couches de convolution permettent d'extraire des motifs spatiaux à différentes échelles, tandis que les connexions de saut assurent la préservation de l'information à haute résolution, essentielle pour la restitution des structures côtières.




FIGURE 8 – Architecture UNet. [11]

Architecture U-NetR++

Le U-NetR++ [12] s'appuie sur le principe général du U-Net, mais introduit un encodeur de type Transformer permettant de modéliser des dépendances spatiales de longue portée. Contrairement aux convolutions, dont le champ réceptif reste local, les mécanismes d'attention auto-régressive permettent de capturer des relations non locales entre différentes régions du domaine spatial.

Dans le U-NetR++, les cartes d'entrées sont d'abord découpées en patches non recouvrants, qui sont ensuite projetés dans un espace latent et traités par plusieurs couches de Transformer. Les représentations intermédiaires issues de différents niveaux du Transformer sont ensuite réinjectées dans le décodeur convolutionnel via des connexions de saut hiérarchiques, assurant une reconstruction multi-échelle cohérente (Figure 9).

Dans ce projet, le U-NetR++ est utilisé dans le cas *autoregressif* et dans le cas *direct*.




FIGURE 9 – Schéma de principe de l'architecture U-NetR++ combinant un encodeur Transformer et un décodeur convolutionnel de type U-Net. [12]

Les modèles U-NetR++ et UNet utilisés dans ce projet sont issue de la librairie MFAI [9] disponible sur le GitHub de Météo-France.

Downscaling direct

Dans l’approche de downscaling direct, le réseau de neurones est entraîné à prédire directement les champs de vagues à haute résolution à partir des champs d’entrée disponibles à plus basse résolution. Cette formulation est conceptuellement simple et permet une mise en œuvre rapide.

Cependant, elle impose au modèle d’apprendre simultanément les structures à grande échelle et les détails fins, ce qui peut s’avérer difficile lorsque les contrastes spatiaux sont importants, notamment à proximité des côtes.

Downscaling sur le résidu

Une alternative au downscaling direct consiste à apprendre uniquement le résidu entre une première estimation à basse résolution interpolée et la cible à haute résolution. Dans ce cas, le réseau de neurones est entraîné à prédire la différence entre les deux champs.

Cette approche présente plusieurs avantages. Elle permet de concentrer l’apprentissage sur les structures fines non résolues par la basse résolution, tout en conservant les informations de grande échelle fournies par le modèle parent. Elle favorise également une meilleure stabilité de l’apprentissage et une convergence plus rapide.

On note $\tilde{\mathbf{Y}}_t$ une estimation interpolée à haute résolution issue du modèle de grande échelle. Le réseau de neurones est alors entraîné à prédire le résidu entre cette estimation et le champ de référence :

$$\mathbf{R}_t = \mathbf{Y}_t - \tilde{\mathbf{Y}}_t, \quad (4)$$

où $\mathbf{Y}_t$ représente le champ de vagues de référence à haute résolution et $\tilde{\mathbf{Y}}_t$ le champ issu de l’interpolation du modèle à plus basse résolution.

La prédiction finale du champ de vagues est alors obtenue en ajoutant le résidu prédit à l’estimation interpolée :

$$\hat{\mathbf{Y}}_t = \tilde{\mathbf{Y}}_t + f_\theta(\mathbf{X}_t), \quad (5)$$

où f_θ désigne le modèle d’apprentissage profond paramétré par θ .

4.5 Modèles autorégressifs

Les modèles autorégressifs intègrent explicitement la dimension temporelle en utilisant les sorties précédentes du modèle comme entrées pour les prédictions futures. Cette approche permet de capturer la dynamique temporelle des champs de vagues et d’assurer une cohérence entre les différentes échéances de prévision.

Dans ce cadre, le modèle est initialisé à partir d’un état de mer donné, puis utilisé de manière itérative pour produire les prévisions aux échéances suivantes. Bien que cette stratégie permette de modéliser des dépendances temporelles complexes, elle est susceptible d’accumuler des erreurs au fil du temps.

4.6 Modèles de diffusion conditionnelle

Les modèles de diffusion [3] constituent une approche probabiliste récente, particulièrement adaptée à la génération de champs spatiaux réalistes. Ils reposent sur un processus de diffusion progressive, dans lequel du bruit est ajouté aux données lors de la phase d’apprentissage, puis progressivement retiré lors de la phase de génération.

Dans le cadre de ce projet, des modèles de diffusion conditionnelle ont été explorés afin de générer des champs de vagues conditionnellement aux forçages atmosphériques et aux paramètres de vagues basse résolution. Toutefois, ces modèles sont généralement plus coûteux en temps de calcul que les architectures déterministes, ce qui constitue un point d'attention dans une perspective opérationnelle.

Les modèles de diffusion reposent sur un processus markovien de corruption progressive des données, au cours duquel un bruit gaussien est ajouté de manière incrémentale à une donnée initiale $\mathbf{y}_0$ selon une séquence de pas temporels $t \in \{1, \dots, T\}$.

Le processus direct consiste à ajouter progressivement du bruit gaussien à la donnée initiale :

$$\mathbf{y}_t = \sqrt{\alpha_t} \mathbf{y}_0 + \sqrt{1 - \alpha_t} \boldsymbol{\epsilon}, \quad \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}), \quad (6)$$

où $\alpha_t \in (0, 1)$ est un coefficient déterministe contrôlant le niveau de bruit au pas t , et $\boldsymbol{\epsilon}$ un bruit gaussien isotrope.

Les coefficients α_t sont généralement définis comme le produit cumulatif d'une suite $\{\beta_t\}_{t=1}^T$ telle que :

$$\alpha_t = \prod_{s=1}^t (1 - \beta_s), \quad (7)$$

où β_t représente la variance du bruit ajouté à chaque étape.




FIGURE 10 – Schéma du processus direct d'un modèle de diffusion, du bruit est progressivement ajouté aux données réelles.

Le processus inverse vise à reconstruire progressivement la donnée initiale $\mathbf{y}_0$ à partir d'un bruit pur $\mathbf{y}_T \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$.

Il est modélisé par un réseau de neurones f_θ entraîné à prédire le bruit ajouté :

$$\boldsymbol{\epsilon}_\theta(\mathbf{y}_t, t, \mathbf{x}) \approx \boldsymbol{\epsilon}, \quad (8)$$

où $\mathbf{x}$ représente les variables conditionnelles (vents, champs à basse résolution, etc).

À chaque pas, la reconstruction s'effectue selon :

$$\mathbf{y}_{t-1} = \frac{1}{\sqrt{\alpha_t}} \left(\mathbf{y}_t - \frac{1 - \alpha_t}{\sqrt{1 - \alpha_t}} \boldsymbol{\epsilon}_\theta(\mathbf{y}_t, t, \mathbf{x}) \right) + \boldsymbol{\eta}_t, \quad (9)$$

où $\boldsymbol{\eta}_t \sim \mathcal{N}(\mathbf{0}, \sigma_t^2 \mathbf{I})$ est un bruit optionnel permettant de générer des sorties stochastiques.

L'apprentissage du modèle repose sur la minimisation de l'erreur quadratique entre le bruit réel et le bruit prédit :

$$\mathcal{L}_{\text{diff}} = \mathbb{E}_{t, y_0, \epsilon} \left[\|\epsilon - \epsilon_\theta(y_t, t, \mathbf{x})\|^2 \right]. \quad (10)$$

Comme illustré à la Figure 11, le modèle de diffusion apprend à reconstruire progressivement un champ de vagues à haute résolution à partir d'un bruit initial, en étant conditionné par les sorties de modèles numériques.




FIGURE 11 – Schéma du processus inverse d'un modèle de diffusion illustrant une étape générique de débruitage conditionnée par des variables physiques.

Dans ce projet, la librairie Diffuser [4] de Hugging face a été utilisé pour la diffusion.

Intégration de la temporalité dans le modèle de diffusion

Afin de permettre au modèle de diffusion de tenir compte du contexte temporel de la prévision, nous avons exploré l'intégration de variables temporelles supplémentaires :

- l'échéance (nombre d'heures depuis le run de référence),
- le jour de l'année, encodé avec des fonctions sinus et cosinus pour capturer la cyclicité annuelle,
- l'heure de la journée, encodée de manière similaire pour représenter les variations diurnes.

Ces informations ont été injectées dans le réseau de manière analogue à l'encodage du step de diffusion. Lors des expériences, nous avons constaté que l'ajout du jour de l'année et de l'heure de la journée n'apportait pas d'amélioration notable : le modèle ne valorisait pas ces informations, probablement car la grille coarse fournit déjà un signal temporel suffisant. En revanche, l'échéance a été conservée, via une petite couche linéaire, permettant au modèle d'adapter ses prédictions selon l'échéance de la prévision.

EMA des poids (Exponential Moving Average)

Le modèle de diffusion utilise également une technique d'EMA (Exponential Moving Average) des poids. Cette approche consiste à maintenir une moyenne exponentielle des poids du réseau pendant l'entraînement, et à utiliser cette moyenne pour la génération lors de l'inférence. L'EMA permet de stabiliser l'entraînement, réduire les oscillations et produire des sorties plus lisses et cohérentes, en particulier pour la restitution des structures côtières fines.

Velocity prediction

Dans les modèles de diffusion, l'apprentissage classique consiste à prédire le bruit ϵ ajouté à l'étape t selon l'équation 8.

Une alternative est la velocity prediction ou (v-prediction) : le réseau prédit une combinaison linéaire du signal et du bruit, notée $\mathbf{v}$, qui peut se définir comme :

$$\mathbf{v} = \alpha_t \mathbf{y}_0 - \sqrt{1 - \alpha_t} \epsilon,$$

Ce choix présente deux avantages pratiques :

- amélioration de la stabilité numérique et de la vitesse de convergence dans certains cas.
- meilleure qualité d'échantillonnage final dans certains cas, notamment pour des signaux à forte dynamique spatiale.

4.7 Fonctions de coût et métriques d'évaluation

Fonctions de coût

L'apprentissage des modèles repose sur la minimisation de différentes fonctions de coût adaptées à la nature des données. Les pertes de type L1 et L2 (ou erreur quadratique moyenne) sont utilisées pour mesurer l'écart point à point entre les prédictions et les références.

Erreur absolue moyenne (MAE / L1)

$$\mathcal{L}_{L1} = \frac{1}{N} \sum_{i=1}^N |\hat{y}_i - y_i| \quad (11)$$

Erreur quadratique moyenne (MSE / L2)

$$\mathcal{L}_{L2} = \frac{1}{N} \sum_{i=1}^N (\hat{y}_i - y_i)^2 \quad (12)$$

Perte perceptuelle [6] Afin de mieux prendre en compte la structure spatiale des champs, une perte perceptuelle a également été considérée. Celle-ci repose sur la comparaison des caractéristiques extraites par un réseau de neurones pré-entraîné, permettant de pénaliser les différences de texture et de structure plutôt que les erreurs locales. La Figure 12 représenté le fonctionnement de cette loss.

$$\mathcal{L}_{perc} = \sum_l \|\phi_l(\hat{\mathbf{y}}) - \phi_l(\mathbf{y})\|_2^2 \quad (13)$$

Avec ϕ_l l'activation de la l^{ieme} couche du réseau.




FIGURE 12 – Schéma de la perte perceptuelle [13].

Métriques d'évaluation

Les performances des modèles sont évaluées à l'aide de métriques quantitatives issues de la littérature, telles que l'indice de similarité structurelle (SSIM) et le scatter index (SI). Ces métriques permettent de compléter l'analyse des erreurs classiques en prenant en compte la cohérence spatiale et la dispersion relative des prédictions.

Les résultats sont également analysés de manière qualitative à travers la visualisation de champs de vagues et la comparaison avec les sorties des modèles physiques de référence, en lien avec les attentes des prévisionnistes marins.

Indice de similarité structurelle (SSIM) [10] Le SSIM prend en compte les contrastes, la luminance et la structure des champs, ce qui le rend particulièrement pertinent pour l'évaluation de champs géophysiques spatialisés.

$$\text{SSIM}(x, y) = \frac{(2\mu_x\mu_y + c_1)(2\sigma_{xy} + c_2)}{(\mu_x^2 + \mu_y^2 + c_1)(\sigma_x^2 + \sigma_y^2 + c_2)} \quad (14)$$

où :

μ_x et μ_y sont la moyenne de la luminosité des deux images.

σ_x^2 et σ_y^2 sont les variances des images respectives.

σ_{xy} la covariance entre les deux images.

c_1 et c_2 des constantes pour la stabilité.

Le SSIM est compris entre 0 et 1, 1 correspondant au SSIM de deux images identiques. L'objectif est d'être le plus proche de 1.

Scatter Index L'indice de dispersion (Scatter Index, SI) est couramment utilisé en océanographie pour évaluer la qualité relative des prévisions de vagues. Dans notre cas, le scatter index est calculé entre les prédictions et les observations faites par satellites ou par bouées sur le paramètre SWH. Les observations sont illustrées sur la Figure 15.

$$\text{SI} = 100 * \frac{\sqrt{(\overline{(x - \text{obs})^2}) - (\overline{(x - \text{obs})})^2}}{\overline{y}} \quad (15)$$

Le SI est une métrique à minimiser, des prédictions identiques aux observations donnant un score de 0.




FIGURE 13 – Observations du satellite Jason 3 le 20 décembre 2023.




FIGURE 14 – Bouées disponibles autour de la Bretagne.

FIGURE 15 – Exemples d’observations pour le paramètre SWH disponibles sur Copernicus [1].

Remarques D’autres satellites altimétriques fournissent une estimation de la hauteur significative de la mer totale comme : Sentinel 6A, Sentinel 3B, Sentinel 3A, Nadir...ect

5 Résultats

5.1 Protocole d’évaluation

L’évaluation des modèles proposés a été réalisée sur une période indépendante de l’apprentissage, afin d’éviter tout biais lié au surapprentissage. Les performances ont été analysées à la fois de manière quantitative, à l’aide de métriques statistiques, et qualitative, via l’inspection visuelle des champs de vagues reconstruits. Les prédictions issues des modèles d’apprentissage profond sont comparées aux sorties du modèle physique de référence WW3 à haute résolution, considéré comme vérité terrain dans cette étude.

5.2 Modèles évalués

Les modèles comparés dans cette étude sont les suivants :

- Downscaling direct (U-NetR++ avec une loss MSE).
- Downscaling direct avec loss combinée (U-NetR++ avec loss L1 + perceptuelle).
- Modèle autorégressif (U-NetR++).
- Apprentissage sur le résidu entre la basse et haute résolution avec loss L1 + perceptuelle.
- Modèle de diffusion optimisée entraîné sur $v_prediction$ (mixed-precision, compilation du graph de calcul, batch size augmenté).

5.3 Résultats qualitatifs

Visualisations

Les figures suivantes présentent, pour un même pas de temps, les sorties comparées : référence MFWAM interpolé, référence WW3 et prédictions des modèles. Afin de simplifier la lecture, seules les variables SWH, SHPS et MPWW sont représentées.




FIGURE 16 – Comparaison des prédictions pour la même échéance pour les modèles directs.




FIGURE 17 – Comparaison des prédictions pour la même échéance pour le modèle autorégressif à des pas de temps 0h et 10h.




FIGURE 18 – Comparaison des prédictions entre MFWAM, WW3 et la version optimisée de la diffusion sur $v_prediction$.

Analyse détaillée des résultats visuels

Downscaling direct (MSE) La sortie du modèle entraîné uniquement sur MSE apparaît visuellement très lissée (Figure 16), particulièrement autour des côtes. La MSE favorise la minimisation de l'erreur quadratique moyenne globale, ce qui tend à "moyenner" les solutions là où les structures locales sont importantes. En pratique, on observe une atténuation des crêtes de houle et une perte de contraste très nette le long des côtes : les détails topographiques fins sont peu restitués.

Downscaling direct (L1 + perceptuelle) L'ajout d'une composante perceptuelle combinée à une perte L1 permet de préserver davantage de détails locaux (Figure 16). La perte perceptuelle pénalise les différences de représentation dans un espace de caractéristiques plutôt que l'écart ponctuel pur. De ce fait, les textures et les contours côtiers sont mieux restitués. Cependant, les structures fines de vagues sont encore peu représentées et légèrement lissées.

Apprentissage sur le résidu (L1 + perceptuelle) La stratégie consistant à apprendre le résidu entre la version basse résolution interpolée et la cible haute résolution conduit à une amélioration sensible des structures fines (Figure 16). En apprenant que la correction locale, le modèle se concentre sur les échelles non résolues à la résolution de base, ce qui facilite l'apprentissage et la convergence : on note une meilleure restitution

des bords côtiers et des petits creux de houle. Cette approche donne le meilleur compromis qualité/coût pour les architectures considérées.

Autorégressif Les deux sorties de la Figure 17 illustrent le comportement temporel du modèle autorégressif. L’observation principale est une forte persistance : la prédiction au pas suivant ressemble très fortement à l’état précédent. La sortie produite par le modèle à 10h sera proche de celle produite à 1h et s’éloigne de la vérité terrain. Ce phénomène indique que, pour des pas temporels courts à l’apprentissage (ici 1h), le modèle a appris une stratégie de copie conditionnelle plutôt que de modéliser explicitement la dynamique physique. Un entraînement avec du rollout (apprendre à prédire plusieurs pas et entraîner sur des séquences 1h puis 3h, etc.) aurait pu atténuer cet effet, mais a été volontairement écarté pour conserver la focalisation sur la tâche de downscaling spatial.

Diffusion Les sorties des modèles de diffusion (Figure 18) montrent que la diffusion est capable de générer des champs spatialement cohérents et texturés. La diffusion opère en reconstruisant étape par étape à partir du bruit, ce qui favorise la diversité et la cohérence statistique des champs générés. Les différences fines par rapport au modèle résidu restent à quantifier avec les métriques (Table 3).

Synthèse visuelle Globalement, l’ordre qualitatif observé (du plus lisse au plus détaillé) est :

direct (MSE) → direct (L1+perc) → diffusion ∼ résidu (L1+perc).

Les modèles résiduels et de diffusion permettent de mieux reconstruire les structures fines, notamment à proximité des côtes, par rapport au downscaling direct.

5.4 Métriques quantitatives

Les performances des modèles de downscaling ont été évaluées à l’aide de plusieurs métriques, notamment l’erreur absolue moyenne (MAE), le Scatter Index (SI) et l’indice de similarité structurelle (SSIM). Ces mesures permettent d’apprécier à la fois la précision globale des prédictions et la qualité des structures spatiales reproduites.

À titre de comparaison, un modèle aléatoire a également été évalué. Plutôt que de générer des prédictions basées sur les entrées basse résolution, ce modèle produit pour chaque paramètre un champ synthétique en tirant des valeurs aléatoires suivant une distribution normale centrée sur la moyenne observée du paramètre et avec un écart-type correspondant à sa variabilité. Cette approche permet de quantifier les performances minimales attendues par hasard.

Modèles	cos_mdps	cos_mdww	mpps (s)	mpww (s)	shps (m)	shww (m)	sin_mdps	sin_mdww	swh (m)
Downscaling direct (MSE)	0,22	0,555	2,3604	3,1949	0,9139	1,8791	0,2899	0,4972	1,9206
Downscaling direct (L1+perc)	0,3134	0,4142	2,1739	3,6283	1,1817	1,7416	0,1897	0,6141	1,9459
Résidu (L1+perc)	0,1447	0,0777	0,9472	0,4897	0,3014	0,3065	0,1205	0,0727	0,2095
Diffusion	0,089	0,1242	0,6801	0,6	0,17	0,24	0,05431	0,12	0,168
MFWAM	0,2267	0,1059	1,1984	0,7179	0,3958	0,4212	0,1361	0,0764	0,3067
Random	0,4793	0,6509	3,1191	3,6937	1,2996	2,0586	0,4129	0,7968	2,1785

TABLE 2 – Métrique Mean Absolute Error sur l’ensemble de paramètres sur l’ensemble du jeu de test.

Model	SI (SWH)
Downscaling direct (MSE)	31,5136
Downscaling direct (L1+perc)	26,1589
Résidu (L1+perc)	7,759
Diffusion	8,4
MFWAM	9,407
Random	40,9526
WW3	6,4952

TABLE 3 – Comparaison des modèles pour les métriques MAE, SI et SSIM sur l'ensemble du jeu de test.

Model	cos_mdps	cos_mdww	mpps	mpww	shps	shww
Downscaling direct (MSE)	0,7384	0,6535	0,7948	0,8205	0,6638	0,7788
Downscaling direct (L1+perc)	0,7914	0,6698	0,845	0,8564	0,7608	0,8377
Résidu (L1+perc)	0,851	0,9173	0,8827	0,9535	0,8865	0,9481
Diffusion	0,8563	0,7721	0,9012	0,8796	0,8993	0,8545
MFWAM	0,7258	0,8178	0,8287	0,8984	0,7637	0,8708
Random	0,3703	0,3306	0,4454	0,3853	0,3331	0,3602

TABLE 4 – Comparaison des modèles pour la métrique SSIM pour tous les paramètres sur l'ensemble du jeu de test.

Analyse des résultats quantitatifs

Erreur absolue moyenne (MAE) La MAE mesure l'écart moyen, en valeur absolue, entre les prédictions du modèle et la référence considérée comme vérité terrain. Elle fournit ainsi une estimation directe de l'erreur commise sur chaque variable, exprimée dans l'unité physique correspondante (mètres pour les hauteurs de vagues, secondes pour les périodes, valeurs adimensionnelles pour les composantes directionnelles normalisées). Une MAE faible indique que les prédictions sont en moyenne proches des valeurs de référence, tandis qu'une MAE élevée traduit un écart systématique important.

Le Tableau 2 met en évidence des différences nettes de performance entre les modèles évalués.

- Le **downscaling direct entraîné avec une perte MSE** présente des erreurs relativement élevées sur l'ensemble des paramètres. Les hauteurs de vagues sont particulièrement affectées (SWH : 1,92 m ; SHPS : 0,91 m), ce qui indique une difficulté à restituer correctement l'amplitude des champs. Les composantes directionnelles (cosinus et sinus) présentent également des écarts non négligeables, traduisant une approximation imparfaite de l'orientation des vagues.
- L'introduction d'une **perte combinée L1 + perceptuelle** améliore partiellement les résultats. Certaines variables directionnelles présentent une diminution de la MAE (par exemple cos_mdww), mais cette amélioration reste inégale selon les paramètres. Les erreurs sur les hauteurs demeurent importantes, ce qui suggère que cette approche améliore la structure spatiale sans corriger entièrement les biais d'amplitude.
- Le **modèle entraîné sur le résidu** montre une amélioration nette et homogène sur l'ensemble des variables. La MAE diminue fortement pour les périodes, les directions et les hauteurs. En particulier, l'erreur sur la hauteur significative totale (SWH) chute à 0,21m, soit une réduction d'un ordre de grandeur par rapport au downscaling direct. Ce résultat indique que le modèle parvient à apprendre efficacement la

correction entre le champ basse résolution et le champ haute résolution, plutôt que de reconstruire l'intégralité du signal.

- Le **modèle de diffusion** obtient les meilleures performances globales. Il présente les plus faibles valeurs de MAE pour la majorité des paramètres, notamment pour les hauteurs (SWH : 0,168m) et les composantes directionnelles. Ces résultats traduisent une capacité accrue à reproduire fidèlement à la fois l'intensité et la structure directionnelle des champs de vagues.

À titre de référence, le modèle **MFWAM** affiche des erreurs intermédiaires, inférieures aux approches de downscaling direct mais supérieures aux méthodes basées sur le résidu et la diffusion. Le modèle aléatoire, quant à lui, présente logiquement les erreurs les plus élevées, confirmant la pertinence de la métrique et la cohérence de l'évaluation.

Scatter Index (SI) Le Scatter Index (SI) pour SWH permet d'évaluer la dispersion relative des erreurs.

Le modèle résiduel réduit fortement le SI (7,76) comparé au downscaling direct (26,15–31,5), ce qui illustre sa capacité à corriger les écarts ponctuels et à reproduire la variabilité locale. Le modèle de diffusion améliore également le SI (8,4), confirmant son efficacité à générer des champs cohérents tout en respectant la variance observée. Les modèles physiques de référence (WW3 et MFWAM) restent les plus cohérents globalement, mais les modèles résiduels et diffusion sont très proches, montrant un potentiel opérationnel.

Indice de similarité structurelle (SSIM) L'indice SSIM permet de mesurer la qualité structurale des prédictions par rapport à la référence haute résolution. Les résultats du tableau 4 montrent que :

- Le Downscaling direct (MSE) atteint un SSIM moyen correct (0,65–0,82 selon les paramètres), mais reste inférieur à celui du modèle résiduel.
- L'ajout de la loss perceptuelle augmente le SSIM, en particulier pour les hauteurs et les composantes directionnelles (SWH : 0,8764).
- Le modèle résiduel atteint les meilleurs scores SSIM sur quasiment tous les paramètres (SWH : 0,9843), montrant une reconstruction fidèle des structures fines.
- Le modèle de diffusion obtient des SSIM comparables au modèle résiduel (SWH : 0,942), tout en conservant la cohérence spatiale.

Synthèse L'analyse globale montre que le downscaling direct produit des champs corrects mais lisses, avec des erreurs sur les détails côtiers. L'ajout d'une perte perceptuelle permet de restituer davantage de structures fines, mais ne suffit pas à atteindre la précision des modèles résiduels. L'approche résiduelle constitue la méthode la plus performante pour ce projet, avec des gains significatifs sur toutes les métriques et une meilleure restitution des détails côtiers. Tandis que le modèle de diffusion se positionne comme une alternative prometteuse, avec des performances comparables à l'approche résiduelle et un apprentissage plus robuste des distributions locales. Les modèles physiques restent indispensables comme référence, mais les approches d'apprentissage profond permettent de réduire le coût de calcul et d'obtenir rapidement des champs haute résolution cohérents.

5.5 Comparaison des coûts de calcul

La Table 5 synthétise les ressources d'entraînement et les temps d'inférence mesurés pour chaque modèle. Les entraînements ont été effectués sur un noeud de 4 GPU.

TABLE 5 – Coûts d’entraînement et temps d’inférence.

Modèle	Précision	Durée entraînement	Inférence sur CPU
Downscaling direct (MSE)	32-bit	1h20	0.19 s
Downscaling direct (L1+perc)	32-bit	3h	0.24 s
Résidu (L1+perc)	32-bit	2h30	0.19 s
Diffusion (optimisée, v-pred)	16-bit mixed	2h	4.88 s

Les modèles basés sur le résidu et le downscaling direct présentent des temps d’inférence très rapides, de l’ordre de 0,2s par champ, ce qui les rend adaptés à une utilisation opérationnelle. Le modèle de diffusion, bien que plus coûteux à l’inférence, reste compatible avec un usage pratique et offre un gain qualitatif notable sur la restitution des détails fins.

5.6 Analyse critique

Les résultats montrent que les approches basées sur l’apprentissage du résidu surpassent le downscaling direct, tant du point de vue des métriques quantitatives que de la qualité visuelle.

Le modèle de diffusion conditionnel présente une capacité accrue à représenter la variabilité spatiale et à générer des champs plus réalistes, au prix toutefois d’un coût de calcul supérieur lors de l’inférence.

Un compromis doit ainsi être trouvé entre précision, temps de calcul et facilité d’intégration opérationnelle, en particulier dans le contexte des contraintes de production de Météo-France.

La Figure 19 compare les prédictions obtenues par le modèle de diffusion et par le modèle direct avec un apprentissage sur le résidu pour une même échéance.




FIGURE 19 – Comparaison des prédictions entre le modèle de diffusion et le modèle direct sur les résidus.

6 Conclusion du projet

Ce projet avait pour objectif de développer et d'évaluer des approches d'apprentissage profond pour le downscaling spatial des états de mer, en s'appuyant sur les modèles physiques de référence WW3 et MFWAM. L'ensemble des travaux réalisés a permis de comparer différentes stratégies, allant du downscaling direct à des méthodes plus avancées, telles que l'apprentissage sur le résidu et les modèles de diffusion conditionnelle.

Les résultats montrent que les approches basées sur la diffusion conditionnelle offrent un

compromis particulièrement intéressant entre fidélité spatiale et restitution des détails fins. En opérant étape par étape à partir du bruit, la diffusion est capable de générer des champs cohérents et texturés, avec une qualité visuelle et structurale proche, voire parfois supérieure, à celle des modèles résiduels. Ces modèles se distinguent notamment par leur capacité à reproduire la variabilité locale et les structures côtières complexes. Cependant, cette approche est plus coûteuse en temps de calcul à l'inférence que les modèles résiduels ou directs, ce qui constitue un facteur à prendre en compte pour une utilisation opérationnelle.

Le modèle résiduel combiné à une loss perceptuelle et L1 demeure légèrement supérieur sur certaines métriques quantitatives (MAE, SSIM), mais la diffusion offre un avantage en termes de cohérence globale et de génération de champs réalistes, ce qui en fait une approche prometteuse pour un déploiement futur.

6.1 Limites de l'étude

Malgré les résultats encourageants obtenus, plusieurs limites doivent être soulignées. Tout d'abord, l'étude s'est concentrée sur une période temporelle restreinte et sur un nombre limité de configurations météorologiques. Bien que ce cadre soit suffisant pour évaluer la faisabilité des approches proposées, il reste insuffisant pour caractériser pleinement la robustesse des modèles face à la variabilité saisonnière, aux situations extrêmes ou aux régimes météorologiques atypiques.

Il est également important de souligner que le problème traité dans ce travail ne se limite pas à une simple amélioration de résolution spatiale au sens classique de la super-résolution d'images. En effet, les champs issus du modèle MFWAM et ceux du modèle WW3 ne reposent pas sur les mêmes hypothèses physiques ni sur la même représentation de l'environnement marin. En particulier, la bathymétrie utilisée diffère entre les deux modèles, ce qui induit des divergences structurelles dans la propagation de la houle et la dynamique des champs simulés.

Dans ce contexte, le modèle appris ne cherche pas uniquement à affiner une information existante, mais doit également apprendre à corriger des biais structurels liés au modèle source, tout en reconstruisant des structures fines cohérentes avec la physique représentée par WW3. L'utilisation des analyses WW3 comme vérité de référence complexifie donc le problème, qui se rapproche davantage d'une tâche de traduction entre modèles que d'un simple downscaling spatial.

Cette particularité rend l'apprentissage plus difficile, mais également plus intéressant d'un point de vue scientifique, car elle implique que le modèle doit apprendre à composer avec des différences de dynamique, de paramétrisation et de résolution, et non uniquement avec une perte d'information liée au changement d'échelle.

6.2 Perspectives d'amélioration méthodologiques

Plusieurs axes d'amélioration peuvent être envisagés à court et moyen terme afin d'enrichir et de consolider les résultats obtenus.

Apprentissage dans l'espace latent

Une première piste consisterait à effectuer le downscaling non plus directement dans l'espace physique, mais dans un espace latent appris par un autoencodeur. Cette approche permettrait :

-
- de réduire la dimension du problème,
 - d’accélérer l’apprentissage,
 - et de faciliter l’utilisation de modèles génératifs complexes, notamment les modèles de diffusion.

Cette stratégie, aujourd’hui largement utilisée dans les modèles de diffusion récents (latent diffusion models), pourrait améliorer significativement le compromis entre précision des résultats et coût de calcul.

Amélioration de la résolution effective

Dans ce travail, le passage de 10 km à 5 km constitue déjà un facteur d’augmentation significatif. Toutefois, une approche progressive pourrait être envisagée, par exemple :

- apprentissage par patches afin de mieux exploiter la mémoire GPU,
- intégration d’un mécanisme de downscaling interne au réseau,
- passer à un apprentissage de 10 km à 1 km.

Ces stratégies permettraient d’envisager une montée en résolution plus stable et plus réaliste, tout en maîtrisant la complexité du modèle.

Enrichissement des variables d’entrée

Plusieurs variables explicatives pourraient être ajoutées afin d’améliorer la cohérence physique des prédictions :

- les champs de vent issus d’ARPEGE, particulièrement pertinents à courte échéance,
- les courants océaniques, qui influencent directement la propagation de la houle.

L’intégration conjointe de ces informations permettrait d’orienter le modèle vers une compréhension plus physique des mécanismes sous-jacents.

6.3 Perspectives spécifiques aux modèles de diffusion

Les modèles de diffusion se sont révélés particulièrement prometteurs dans le cadre de ce travail. Plusieurs axes d’amélioration peuvent être envisagés :

- **Apprentissage sur le résidu** : appliquer la diffusion non pas sur le champ brut, mais sur la différence entre basse et haute résolution afin de concentrer l’apprentissage sur les structures fines.
- **Étude de l’incertitude** : la diffusion permettant de générer plusieurs réalisations, une analyse statistique (écart-type, quantiles, cartes d’incertitude) permettrait d’exploiter pleinement cet aspect probabiliste.
- **Optimisation du coût de calcul** : bien que performants, ces modèles restent coûteux à l’inférence. Des approches telles que la réduction du nombre d’étapes de diffusion ou l’utilisation de schémas de sampling accélérés différent de DDPM pourraient être explorées.
- **Analyse fine des distributions générées** : via des cartes d’erreur spatialisées ou des analyses spectrales permettant de mieux caractériser les différences entre modèles.

6.4 Vers une mise en production opérationnelle

D'un point de vue applicatif, les résultats obtenus montrent qu'un modèle de downscaling basé sur l'apprentissage profond pourrait constituer un outil complémentaire pertinent aux chaînes opérationnelles existantes.

Même si l'objectif d'une résolution de 200 m reste ambitieux à court terme, une résolution intermédiaire de l'ordre du kilomètre représenterait déjà un gain significatif pour de nombreuses applications côtières, telles que la prévision locale, la sécurité maritime ou les études d'impact.

Une intégration opérationnelle nécessiterait néanmoins :

- une phase de validation étendue sur plusieurs années,
- une analyse de robustesse en conditions extrêmes,
- une évaluation approfondie des temps de calcul et des contraintes de production.

Remerciements

Je souhaite tout d'abord exprimer ma profonde gratitude à l'ensemble de l'équipe du LabIA pour son accueil chaleureux et son accompagnement tout au long de ce projet. Parmi mes collègues, je remercie particulièrement Léa Berthomier pour son aide régulière et précieuse, ainsi que Théo Tournier, Oscar Dewasmes, Frank Guibert et Bruno Pradel pour leurs conseils significatifs et leurs relectures de code qui ont contribué à la progression du projet. Je remercie également Isabelle Beau, cheffe du LabIA, pour son écoute, sa disponibilité et sa capacité à créer un environnement de travail stimulant et structuré.

Je remercie également l'équipe métier DIROP/MAR/RD, et plus particulièrement Lotfi Aouf et Alice Dalphinnet, pour leur accompagnement et leurs conseils, qui ont permis d'ancrer ce projet dans les besoins opérationnels.

Enfin, je suis reconnaissante d'avoir pu, durant mes deux années d'alternance, participer à d'autres initiatives passionnantes de l'équipe, telles que le portage d'un projet d'estimation de précipitations par apprentissage profond de Tensorflow vers Pytorch ou le développement d'un RAG (chatbot), renforçant mes compétences techniques et ma capacité à m'adapter à des problématiques scientifiques variées.

7 Conclusion personnelle

Au-delà des résultats scientifiques, ce projet a constitué une expérience particulièrement formatrice sur les plans méthodologique, technique et organisationnel. Il s'est inscrit dans un cadre de travail collaboratif, impliquant des échanges réguliers avec les membres de l'équipe, notamment à travers la relecture de code, la validation des choix méthodologiques et la discussion des résultats. Cette dynamique collective a favorisé l'adoption de pratiques de développement rigoureuses, telles que l'utilisation systématique de tests, le typage du code, la structuration claire des expériences, l'usage de conteneurs Docker ainsi que la gestion des versions et des expérimentations via un système d'étiquetage explicite.

Dans cette continuité, le cadre de développement imposé a également permis de limiter l'apparition de dette technique, problématique fréquente dans les projets mêlant recherche et développement. La structuration du code, la standardisation des expériences, ainsi que l'attention portée à la lisibilité et à la maintenabilité des implémentations constituent des acquis importants, directement transférables à un environnement professionnel. Par

ailleurs, j'ai particulièrement apprécié la philosophie de l'équipe qui privilégie l'utilisation d'une intelligence artificielle frugale, optimisée pour limiter le coût de calcul tout en restant performante, ce qui m'a sensibilisé à l'importance de l'efficacité algorithmique dans un cadre opérationnel.

Sur le plan technique, ce projet a permis de consolider des compétences avancées en apprentissage profond, et plus particulièrement sur les modèles génératifs et les modèles de diffusion. Leur mise en oeuvre a nécessité une compréhension fine des mécanismes d'apprentissage, des enjeux de stabilité numérique ainsi que des compromis entre performance et coût de calcul. La manipulation de volumes importants de données géophysiques, la gestion des ressources GPU et l'optimisation des temps d'entraînement ont également constitué des aspects centraux du travail, se rapprochant des conditions de développement rencontrées dans un cadre opérationnel réel. L'accès à des infrastructures GPU performantes et à un cadre de développement structuré a également été particulièrement formateur et motivant.

Enfin, cette expérience a permis d'acquérir une vision globale du cycle de développement d'un modèle d'apprentissage profond appliqué aux sciences de l'environnement : depuis la formulation du problème scientifique, le choix des architectures et des fonctions de coût, jusqu'à l'évaluation critique des résultats et leur interprétation dans un contexte applicatif. Elle a également renforcé mes compétences interpersonnelles et organisationnelles, en apprenant à structurer mes développements dans un cadre collaboratif, à suivre les bonnes pratiques de codage et à gérer des projets scientifiques à long terme. Cette expérience a ainsi consolidé à la fois mes compétences techniques, ma compréhension des enjeux scientifiques et opérationnels, et ma capacité à travailler efficacement dans un environnement de recherche appliquée.

Glossaire

Organisation

LabIA Laboratoire d'Intelligence Artificielle de Météo-France.

DirOP/MAR Direction des Opérations / Département Marine et Océanographie.

DSM Direction des Services Météorologiques.

Vocabulaire Météorologique et Océanographique

MFWAM (Météo-France Wave Model) Modèle de prévision des vagues à grande échelle (large). Dans ce projet, il fournit les données d'entrée à basse résolution (10 km).

WW3 (WaveWatch III) Modèle spectral de vagues, utilisé ici en configuration côtière haute résolution. Il sert de vérité terrain pour l'entraînement.

ARPEGE (Action de Recherche Petite Échelle Grande Échelle) Modèle atmosphérique global de Météo-France. Il fournit les champs de vent (à 10 m) utilisés comme forçage.

AROME (Application de la Recherche à l'Opérationnel à Méso-Echelle) Modèle atmosphérique régional de Météo-France.

Bathymétrie Topographie des fonds marins (profondeur). C'est une donnée statique essentielle pour modéliser le comportement des vagues près des côtes.

IFS/CEP Modèle du Centre Européen pour les Prévisions Météorologiques à Moyen Terme.

Hycom2D Modèle hydrodynamique fournissant les courants de surface et le niveau de la mer.

Forçage En météorologie et en climatologie, le terme forçage désigne une perturbation extérieure qui vient modifier l'état d'équilibre d'un système (l'atmosphère, une masse d'air ou le climat global).

Barotrope En océanographie, c'est une quantité moyennée sur la verticale (ex. vitesse barotrope). Une vitesse barotrope est constante de la surface au fond.

Composante Zonale (U) Composante du vent soufflant horizontalement d'Ouest en Est (axe des x).

Composante Méridienne (V) Composante du vent soufflant verticalement du Sud au Nord (axe des y).

Vagues-Submersion Phénomène d'inondation côtière causé par l'élévation simultanée du niveau de la mer (marée + surcote) et le déferlement des vagues.

Mer du vent (Wind) Vagues générées localement par le vent soufflant sur la zone.

Houle (Swell) Vagues générées par un vent lointain et s'étant propagées hors de leur zone de génération.

Downscaling (Descente d'échelle) Moyen d'obtenir des informations à l'échelle locale ou régionale à partir de modèles ou d'analyses de données à plus grande échelle.

Paramètres de Vagues

SWH (Significant Wave Height) : Hauteur significative de la mer totale (combinaison de la mer du vent et de la houle).

SHWW (Significant Height of Wind Waves) : Hauteur significative de la mer du vent (vagues générées localement par le vent).

SHPS (Significant Height of Primary Swell) : Hauteur significative de la houle primaire (vagues générées au loin).

MPWW (Mean Period of Wind Waves) : Période moyenne de la mer du vent.

MPPS (Mean Period of Primary Swell) : Période moyenne de la houle primaire.

MDWW (Mean Direction of Wind Waves) : Direction moyenne de la mer du vent.

MDPS (Mean Direction of Primary Swell) : Direction principale de la houle primaire.

Bibliographie

- [1] European Union Copernicus Marine Service. Copernicus marine data store. <https://data.marine.copernicus.eu>, 2025. Portail de données océaniques fournissant des produits physiques et environnementaux.
- [2] L. Glawion, J. Polz, H. Kunstmann, and et al. Global spatio-temporal era5 precipitation downscaling to km and sub-hourly scale using generative ai. *npj Climate and Atmospheric Science*, 8 :219, 2025. doi : 10.1038/s41612-025-01103-y. URL <https://doi.org/10.1038/s41612-025-01103-y>.
- [3] Jonathan Ho, Ajay Jain, and Pieter Abbeel. Denoising diffusion probabilistic models, 2020. URL <https://arxiv.org/abs/2006.11239>.
- [4] Hugging Face. Hugging face diffusers documentation. <https://huggingface.co/docs/diffusers/index>, 2025. Documentation officielle de la bibliothèque Diffusers pour les modèles de diffusion.
- [5] Kevin Höhle, Michael Kern, Timothy Hewson, and Rüdiger Westermann. A comparative study of convolutional neural network models for wind field downscaling. *Meteorological Applications*, 27(6), November 2020. ISSN 1469-8080. doi : 10.1002/met.1961. URL <http://dx.doi.org/10.1002/met.1961>.
- [6] Justin Johnson, Alexandre Alahi, and Li Fei-Fei. Perceptual losses for real-time style transfer and super-resolution, 2016. URL <https://arxiv.org/abs/1603.08155>.
- [7] François Meyer. Décrire l'état de la mer, l'échelle de douglas. <https://www.actunautique.com/2021/04/decrire-l-etat-de-la-mer-l-echelle-de-douglas.html>, 2021. Consulté le 20 janvier 2026.
- [8] Météo-France. Descriptif du modèle wavewatch iii utilisé par météo-france. https://donneespubliques.meteofrance.fr/client/document/20170715_descriptif_ww3_235.pdf, 2017. Consulté le 20 janvier 2026.
- [9] Météo-France. Mfai : Météo-france's ai python package. <https://github.com/meteofrance/mfai>, 2024. Dépôt GitHub utilisé pour l'implémentation des architectures et des outils IA.
- [10] Jim Nilsson and Tomas Akenine-Möller. Understanding ssim, 2020. URL <https://arxiv.org/abs/2006.13846>.
- [11] Olaf Ronneberger, Philipp Fischer, and Thomas Brox. U-net : Convolutional networks for biomedical image segmentation. *arXiv*, abs/1505.04597, 2015. URL <https://arxiv.org/pdf/1505.04597.pdf>. Consulté le 20 janvier 2026.

-
- [12] Abdelrahman Shaker, Muhammad Maaz, Hanoona Rasheed, Salman Khan, Ming-Hsuan Yang, and Fahad Shahbaz Khan. Unetr++ : Delving into efficient and accurate 3d medical image segmentation, 2024. URL <https://arxiv.org/abs/2212.04497>.
- [13] Long Teng, ZhongLiang Fu, and Yu Yao. Interactive translation in echocardiography training system with enhanced cycle-gan. *IEEE Access*, PP :1–1, 06 2020. doi : 10.1109/ACCESS.2020.3000666.
- [14] Hendrik L. Tolman, Bhavani Balasubramaniyan, Lawrence D. Burroughs, Dmitry V. Chalikov, Yung Y. Chao, Hsuan S. Chen, and Vera M. Gerald. Development and implementation of wind-generated ocean surface wave modelsat ncep. *Weather and Forecasting*, 17(2) :311 – 333, 2002. doi : 10.1175/1520-0434(2002)017<0311:DAIOWG>2.0.CO;2. URL https://journals.ametsoc.org/view/journals/wefo/17/2/1520-0434_2002_017_0311_daiowg_2_0_co_2.xml.
- [15] E. Tomasi, G. Franch, and M. Cristoforetti. Can ai be enabled to perform dynamical downscaling? a latent diffusion model to mimic kilometer-scale cosmo5.0_clm9 simulations. *Geoscientific Model Development*, 18(6) :2051–2078, 2025. doi : 10.5194/gmd-18-2051-2025. URL <https://gmd.copernicus.org/articles/18/2051/2025/>.
- [16] Robbie A. Watt and Laura A. Mansfield. Generative diffusion-based downscaling for climate, 2024. URL <https://arxiv.org/abs/2404.17752>.